

华中科技大学学报(自然科学版)
*Journal of Huazhong University of Science and Technology(Natural Science Edition)*
ISSN 1671-4512,CN 42-1658/N

# 《华中科技大学学报(自然科学版)》网络首发论文

题目：基于主动学习深度神经网络模型的结构可靠性分析方法
作者：翟东升，雷宗建，罗辉
DOI：10.13245/j.hust.260075
网络首发日期：2026-10-08
引用格式：翟东升，雷宗建，罗辉．基于主动学习深度神经网络模型的结构可靠性分析方法[J/OL]．华中科技大学学报(自然科学版).
https://doi.org/10.13245/j.hust.260075



**网络首发**：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

**出版确认**：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-10-08 16:50:18　网络首发地址：https://link.cnki.net/urlid/42.1658.N.20261008.1521.001

DOI：10.13245/j.hust.260075

# 基于主动学习深度神经网络模型的结构可靠性分析方法

翟东升[1]　雷宗建[2]　罗辉[1,3]

(1．石河子大学水利建筑工程学院，新疆 石河子 832003；
2．湖北交投荆楚建设管理有限公司，湖北 武汉 430072；
3．华中科技大学土木与水利工程学院，湖北 武汉 430072)

**摘要**　为提高蒙特卡罗结构可靠性分析中极限状态面附近关键样本的获取能力，提出一种基于主动学习深度神经网络的结构可靠性分析方法。该方法包括初始建模和主动学习更新两个阶段。首先，在随机变量空间中构建初始实验设计，并建立初始深度神经网络代理模型。随后，根据代理模型预测结果筛选极限状态面附近的候选样本。结合样本分布特征选取新增样本，并根据其真实函数值调整实验设计。在此基础上，迭代更新代理模型，直至失效概率估计满足收敛要求。通过二维多失效模式函数、屋面桁架、40 维函数和桁架桥有限元模型验证所提方法。结果表明，该方法在多失效模式、高维及隐式可靠性问题中均具有较好的失效概率估计精度和效率。

**关键词**　可靠性分析；代理模型；深度神经网络；主动学习；极限状态面

**中图分类号**　TB114.3；TP18　　**文献标志码**　A　　**文章编号**　1671-4512(xxxx)xx-xxxx-xx

# Reliability analysis method based on an active learning deep neural network model

*Dongsheng Zhai*[1]　*Zongjian Lei* [2]　*Hui Luo*[1,3]

(1．College of Water Conservancy & Architectural Engineering, Shihezi University, Shihezi 832003, China；
2．Hubei Jiaotou Jingchu Construction Management Co., Ltd., Wuhan 430072, Hubei, China;
3．School of Civil and Hydraulic Engineering, Huazhong University of Science and Technology, Wuhan 430072, China)

**Abstract**　To improve the acquisition of critical samples near the limit state surface in Monte Carlo simulation-based structural reliability analysis, an active learning deep neural network method is proposed. The method consists of two stages: initial modeling and active learning updating. First, an initial design of experiments is constructed in the random variable space, and an initial deep neural network surrogate model is established. Subsequently, candidate samples near the limit state surface are identified based on the surrogate model predictions. New samples are then selected by considering their spatial distribution, and the design of experiments is adjusted according to their true limit state function values. The surrogate model is iteratively updated until the failure probability estimate satisfies the convergence criterion. The proposed method was validated using a two-dimensional multi-failure-mode function, a roof truss, a 40-dimensional function, and a finite element model of a truss bridge. The results showed that the proposed method achieved good failure probability estimation accuracy and computational efficiency for multi-failure-mode, high-dimensional, and implicit reliability problems.

**Key words**　reliability analysis; surrogate model; deep neural networks; active learning; limit state surface

工程结构在服役过程中受到随机荷载、材料属性和环境变化等不确定性因素影响，可能引发失效风险[1,2]。结构可靠性分析通过定量评估结构失效概率，为保障工程结构安全提供重要依据[3]。对于复杂工程结构，极限状态函数通常涉及高成本数值分析，直接计算需要大量模型调用。为提高计算效率，代理模型被用于近似输入变量与结构响应之间的映射关系，并结合主动学习提高极限状态面附近的预测精度。其中，AK-MCS[4]是具有代表性的方法。

除 Kriging 外，多项式混沌展开、支持向量机和人工神经网络等代理模型也被广泛用于结构可靠性分析[5]。然而，在主动学习过程中，代理模型需要随新增样本不断更新。若每次迭代均从头训练模型，不仅难以充分利用已有模型信息，还会产生重复优

化开销。DNN 具有较强的学习能力和近似能力，为复杂可靠性问题提供了有效的代理建模工具[6-9]。相关研究进一步拓展了 DNN 在结构可靠性分析中的应用[10-12]，其中 Zhai 等[12]采用增量更新 DNN 利用已有模型参数，减少主动学习过程中的重复训练。尽管如此，样本质量与分布仍是影响代理模型可靠性分析精度的关键。相比一次性实验设计，自适应实验设计通过迭代增加极限状态面附近的关键样本，可提高代理模型在该区域的近似精度[13,14]。现有自适应采样方法主要分为基于方差和无方差两类[15]。基于方差的方法[16,17]利用代理模型的预测均值和方差信息选择新增样本，在 Kriging 可靠性分析中得到广泛应用[18]。然而，这类方法依赖代理模型提供预测方差，对于不具备该统计信息的模型，如深度神经网络，难以直接应用。相比之下，无方差方法不依赖预测方差，具有更广泛的模型适用性[19]。该类方法通常结合样本到极限状态面的距离或样本分布特征进行样本筛选[20]。然而，现有无方差采样策略仍难以兼顾样本空间探索与关键区域利用，对新增样本选择与实验设计样本组成的协同优化考虑不足。因此，在识别潜在极限状态区域的同时，优化关键样本的空间分布和实验设计，是提高可靠性估计精度的关键。

针对上述问题，本文提出一种基于主动学习深度神经网络模型的结构可靠性分析方法。该方法首先，基于初始实验设计构建初始代理模型。随后，根据模型预测结果从安全域和失效域两侧筛选潜在极限状态样本，并在候选子集中结合 Maximin 准则选取新增样本，以增强样本在极限状态面附近的空间分布。同时，根据新增样本的真实极限状态函数值剔除远离极限状态面的样本，逐步优化实验设计的样本质量。最后，通过四个算例验证所提方法的可靠性估计精度与效率。

# 1 相关理论

## 1.1 基于蒙特卡洛模拟的结构可靠性分析

结构可靠性分析旨在定量评估工程结构在多源不确定性作用下发生失效的概率[3]。其失效概率可表示为：

$$P_f = P[G(\boldsymbol{X}) \le 0] = \int_{G(\boldsymbol{x})\le 0} f_{\boldsymbol{X}}(\boldsymbol{x})d\boldsymbol{x} \quad (1)$$

其中，$\boldsymbol{X} = \{X_1, X_2, \cdots X_n\}$为$n$维输入随机变量向量，$\boldsymbol{x} = \{x_1, x_2, \ldots, x_n\}^{\mathrm{T}}$为其一个实现，$f_{\boldsymbol{X}}(\boldsymbol{x})$为联合概率密度函数，$G(\boldsymbol{x})$为极限状态函数值。根据$G(\boldsymbol{x})$的取值，结构状态可划分为：

$$G(\boldsymbol{x})\begin{cases} > 0, & \text{安全域} \\ = 0, & \text{极限状态} \\ < 0, & \text{失效域} \end{cases} \quad (2)$$

由于式（1）中的高维积分通常难以解析求解，常采用 MCS 计算结构失效概率，其计算形式为：

$$P_f = \frac{1}{N_{MCS}}\sum_{i=1}^{N_{MCS}} I\left(\boldsymbol{x}^{(i)}\right) \quad (3)$$

其中，$N_{MCS}$为模拟的总样本数。$\boldsymbol{x}^{(i)}$为第$i$个随机样本。$I(\cdot)$为失效指示函数。定义如下：

$$I(\boldsymbol{x}) = \begin{cases} 1, & if\ \ G(\boldsymbol{x}) \le 0 \\ 0, & if\ \ G(\boldsymbol{x}) > 0 \end{cases} \quad (4)$$

当样本数量充分时，MCS 能够获得稳定的失效概率估计，但其通常需要大量极限状态函数调用，在复杂结构可靠性分析中计算成本较高。

## 1.2 深度神经网络的建模

DNN 通常由输入层、隐藏层和输出层组成[10]。设网络包含$L$个隐藏层，每个隐藏层的神经元数量为$n_h$。对于输入样本$\boldsymbol{x}$，其前向传播过程表示为：

$$\begin{cases} \boldsymbol{h}^{(0)} = \boldsymbol{x} \\ \boldsymbol{h}^{(l)} = \sigma\left(\boldsymbol{W}^{(l)}\boldsymbol{h}^{(l-1)} + \boldsymbol{b}^{(l)}\right) \ , l = 1, \ldots, L \\ \hat{G}(\boldsymbol{x};\boldsymbol{\theta}) = \boldsymbol{W}^{(L+1)}\boldsymbol{h}^{(L)} + \boldsymbol{b}^{(L+1)} \end{cases} \quad (5)$$

其中，$\boldsymbol{h}^{(l)}$为第$l$个隐藏层的输出，$\boldsymbol{W}^{(l)}$和$\boldsymbol{b}^{(l)}$分别为第$l$层的权重矩阵和偏置向量，$\boldsymbol{\theta}$表示 DNN 的全部可训练参数，$\hat{G}(\boldsymbol{x};\boldsymbol{\theta})$为代理模型的预测值。隐藏层采用 Swish 激活函数。模型采用均方误差作为训练损失函数：

$$L(\boldsymbol{\theta}) = \frac{1}{N}\sum_{i=1}^{N}\left[\hat{G}(\boldsymbol{x};\boldsymbol{\theta}) - G\left(\boldsymbol{x}^{(i)}\right)\right]^2 \quad (6)$$

其中，$N$为训练样本数量，$G\left(\boldsymbol{x}^{(i)}\right)$和$\hat{G}(\boldsymbol{x};\boldsymbol{\theta})$分别为第$i$个样本的真实极限状态函数值和代理模型预测值。网络参数采用带权重衰减的自适应矩估计优化方法进行更新。

在主动学习过程中，DNN 模型需要随试验设计更新而持续训练。若每轮迭代均从随机初始化参数重新训练，将产生重复优化开销。为此，采用增量更新策略，将上一轮获得的最优模型参数作为当前轮训练的初始参数[12]：

$$\boldsymbol{\theta}_0^{(\tau)} = \boldsymbol{\theta}_*^{(\tau-1)} \quad (7)$$

其中，$\boldsymbol{\theta}_0^{(\tau)}$为第$\tau$次主动学习迭代的初始参数，$\boldsymbol{\theta}_*^{(\tau-1)}$为上一轮迭代获得的最优参数。第$\tau$次迭代的数据集由上一轮更新后保留的样本和本轮新增样本组成：

$$D^{(\tau)} = D_{\mathrm{ret}}^{(\tau-1)} \cup D_{\mathrm{new}}^{(\tau)} \quad (8)$$

其中，$D^{(\tau)}$为第$\tau$次迭代的数据集，$D_{\mathrm{ret}}^{(\tau-1)}$为上一轮保留的样本集，$D_{\mathrm{new}}^{(\tau)}$为本轮新增样本及其真实极限状态函数值。通过更新训练数据并继承上一轮模型参数，实现代理模型的连续增量更新。

考虑到结构可靠性分析更加关注极限状态面附近的近似精度，将当前试验设计按照$|G(\boldsymbol{x})|$从小到大排序，并按排序结果等间隔选取 20%的样本作为验证集，其余 80%作为训练集。训练过程中，采用指数移动平均平滑验证损失，平滑系数取 0.9；当平滑验证损失连续 50 个训练轮次未改善时，将学习率乘以 0.8 并重新统计未改善轮次；当最近 200 个训练轮次内最优平滑验证损失的相对改善小于$10^{-3}$时终止训练。最终取平滑验证损失最小时对应的模型参数作为当前迭代的最优参数，并用于下一轮主动学习迭代。

## 2　基于主动学习深度神经网络的结构可靠性分析方法

### 2.1　初始建模阶段：基于初始实验设计构建初始模型

由于极限状态面的位置通常未知，采用 Maximin 距离设计构建初始实验设计[11]，通过最大化样本之间的最小距离提高初始样本对输入空间的覆盖性。随后，采用 10 折交叉验证与贝叶斯优化确定深度神经网络的主要超参数，并基于初始实验设计建立初始代理模型。

### 2.2　主动学习更新阶段：自适应采样扩充实验设计更新模型

基于初始实验设计构建的 DNN 模型能够初步表征极限状态函数的整体变化特征，但其对极限状态面的近似精度仍受限于样本分布和数量。为此，本节提出一种不依赖预测方差的主动学习策略。

首先，利用当前 DNN 模型对候选样本集$S_c$中的样本进行极限状态函数预测，得到对应的预测值。根据预测结果，将候选样本划分为预测失效域和预测安全域。随后，分别在预测失效域和预测安全域内按照预测值绝对值由小到大的顺序进行排序。具体而言，从失效域中选取最接近极限状态面的前$D_f^{top}$个样本，构成集合$D_f^{top}$；同时，从安全域中选取数量相同、同样靠近极限状态面的样本，构成集合$D_s^{top}$。随着迭代次数的增加，筛选比例按 0.8 的倍数逐步递减。参考已有文献[7,9]，第$k$次主动学习迭代的筛选比例定义：

$$p_k = \max(\mathrm{p_{min}}, p_0 \times 0.8^{k-1}) \qquad (9)$$

其中，$p_0$为初始筛选比例；$p_{\min}$为最低筛选比例，取 0.1。该递减机制使主动学习过程在前期保持较大的搜索范围，而在后期更加聚焦于极限状态面附近的关键区域。通过上述筛选，原始候选样本集$S_c$被压缩为集中分布于极限状态面附近的候选子集$S_{cs}$。

然后，采用 Maximin 准则从候选子集$S_{cs}$中选取代表性样本。对于候选子集中的每一个样本点$\boldsymbol{x}$，首先计算其与当前实验设计中所有已有样本点$\boldsymbol{x}_j$之间的最小欧氏距离。然后，在所有候选样本对应的最小距离中，选择距离最大的样本作为新增样本点。该策略既保证新增样本位于极限状态面附近，又能够增强样本的空间分布[20]。公式如下：

$$\begin{cases} d(\boldsymbol{x}) = \min\limits_{\boldsymbol{x}_j \in \text{实验设计}} \| \boldsymbol{x} - \mathbf{x}_j \| \\ \boldsymbol{x}^* = \arg\max\limits_{\boldsymbol{x} \in S_{\mathrm{cs}}} d(\boldsymbol{x}) \end{cases} \qquad (10)$$

同时，为提高实验设计中极限状态面附近关键样本的占比，采用样本剔除策略调整实验设计。当新增样本满足$|G(\boldsymbol{x}^*)| \le \Delta$时，认为其位于极限状态邻域，其中，$\Delta$为无量纲化判定阈值。此时，将该样本加入实验设计，并剔除其中极限状态函数绝对值最大的已有样本。当$|G(\boldsymbol{x}^*)| > \Delta$时，直接将其加入实验设计即可。通过上述实验设计更新，实验设计能够逐步提高极限状态面附近关键样本的占比。

最后，根据连续迭代过程中失效概率估计结果的收敛程度确定主动学习停止条件。定义收敛指标为：

$$\varepsilon = \frac{\sigma_f}{\mu_f} \qquad (11)$$

其中，$\mu_f$为最近$n_f$次采样迭代所得失效概率的均值，即$\mu_f = \frac{1}{n_f}\sum_{i=1}^{n_f} P_f^{(i)}$。$\sigma_f$为对应的标准差，即$\sigma_f = \sqrt{\frac{1}{n_f}\sum_{i=1}^{n_f}\left(P_f^{(i)} - \mu_f\right)^2}$。参考已有文献[13]，当收敛指标满足$\varepsilon \le \varepsilon_s = 0.02$，即认为失效概率已经收敛。$n_f$取为 10。

### 2.3　所提的可靠性分析流程

整个过程分为初始建模阶段和主动学习更新阶段，其中步骤 1-4 为初始建模阶段，步骤 5-10 为主动学习更新阶段。

1）初始建模阶段

步骤 1：根据输入随机变量的概率分布，采用蒙特卡洛模拟生成用于失效概率估计的样本集$S_{mc} = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_{N_{mc}}\}$，其中$N_{mc}$为样本数量。$S_{mc}$

用于失效概率计算。

步骤 2：生成用于主动学习采样的候选样本集$S_c = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_{N_c}\}$，其中$N_c$为候选样本数量。$S_c$主要用于筛选候选样本。

步骤 3：在候选样本集$S_c$的基础上，采用 Maximin 准则选取初始实验设计样本集$D_{initial} = \{\boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \dots, \boldsymbol{x}^{(n)}\}$。该准则能够增强初始样本在设计空间中的代表性。

步骤 4：基于当前实验设计训练或增量更新 DNN 模型。初始建模时随机初始化网络参数；后续主动学习迭代中继承上一轮最优模型参数。

2）主动学习更新阶段

步骤 5：利用当前 DNN 模型对$S_{mc}$中的样本进行预测，并据此估计失效概率$P_f$。按照工程可靠性分析中常用的统计要求[6]，当$\mathrm{cov}(P_f) \le 0.05$时，认为当前$S_{mc}$的样本规模满足要求；否则，增加$S_{mc}$的样本数量级并重新计算。

步骤 6：根据本文提出的收敛准则计算失效概率收敛指标$\varepsilon$。若$\varepsilon \le \varepsilon_s$，估计结果趋于稳定，主动学习过程停止，进入步骤 10；否则，进入第 7 步，继续执行主动采样与模型更新。

步骤 7：利用当前 DNN 模型对候选样本集$S_c$进行极限状态函数预测，并从中筛选靠近极限状态面的候选子集$S_{cs}$。

步骤 8：在候选子集$S_{cs}$中采用 Maximin 距离准则选择新增样本点$\boldsymbol{x}^*$。具体而言，计算每个候选样本到当前实验设计中已有样本的最小距离，并选取其中最小距离最大的样本作为新增样本。

步骤 9：获得新增样本$\boldsymbol{x}^*$后，调用极限状态函数计算其函数值。采用样本剔除策略更新实验设计。随后，将更新后的实验设计返回步骤 4。通过重复执行步骤 4-9，直至满足收敛判定标准。

步骤 10 输出最终失效概率估计值，终止主动学习。

# 3 案例研究

为了验证所提出方法的有效性，将估计的失效概率与其他先进方法的结果进行对比。在本节中，除非另有明确说明，所提方法的超参数设置为$n_h$ = [16,32] 、 $L$ =3 、 $\eta_t = [1e^{-3}, 1e^{-2}]$ 、 $\lambda = [1e^{-4}, 1e^{-2}]$、$\Delta$=0.1、最大训练轮次为 1000，贝叶斯超参数寻优次数为 5。所有模型训练与采样算法均基于 PyTorch 2.2 实现，每个算例独立运行 10 次，并报告平均统计结果。性能主要通过失效概率（$P_f$）、变异系数（$\mathrm{cov}(P_f)$）、相对误差（$\varepsilon_{Pf}$）和极限状态函数调用次数（$N_{call}$）进行评价。

## 3.1 基于四分支函数的二维算例

算例 1 是一个二维四分支可靠性问题，用于直观展示所提方法的主动采样特性[4]。其极限状态函数为：

$$G(x_1, x_2) = min\begin{cases} 3 + 0.1(x_1 - x_2)^2 - (x_1 + x_2)/\sqrt{2} \\ 3 + 0.1(x_1 - x_2)^2 + (x_1 + x_2)/\sqrt{2} \\ x_1 - x_2 + 7/\sqrt{2} \\ x_2 - x_1 + 7/\sqrt{2} \end{cases} \quad (12)$$

式中，$x_1$、$x_2$均为标准正态分布且相互独立。表 1 给出了不同方法在该算例下的计算结果。

由表 1 可知，所提方法得到的失效概率为$2.175 \times 10^{-3}$，相对误差为 2.51%，函数调用次数平均为 57.6 次。与 AK-MCS-U、AK-MCS-EFF 和 Xiang 方法相比[9]，所提方法进一步减少了极限状态函数调用次数。与方向抽样、重要抽样及其响应面组合方法相比，所提方法能够在保持可接受估计精度的前提下有效降低计算成本。

表 1 不同方法对算例 1 的结果

| 方法 | $N_{call}$ | $P_f$(×10⁻³) | $\varepsilon_{Pf}$(%) | $\mathrm{cov}(P_f)$ (%) |
|---|---|---|---|---|
| MCS | 1×10⁶ | 2.231 | - | 2.12 |
| 方向抽样 | 9192 | 2.6 | 16.54 | 1.96 |
| 重要抽样 | 4750 | 2.2 | 1.39 | 2.13 |
| 方向抽样+响应面 | 830 | 1.0 | 55.18 | 3.16 |
| 重要抽样+响应面 | 3877 | 2.0 | 10.35 | 2.23 |
| AK-MCS-U | 96 | 2.233 | 0.09 | 2.11 |
| AK-MCS-EFF | 101 | 2.232 | 0.04 | 2.11 |
| Xiang | 70 | 2.192 | 1.75 | 2.13 |
| 所提方法 | 57.6 | 2.175 | 2.51 | 2.14 |

图 1 展示了所提方法的主动采样结果。由图 1(a)可见，四分支函数包含多个失效区域，若样本对各分支附近区域覆盖不足，代理模型可能产生局部误判。图 1(b)表明，主动学习新增样本主要分布于极限状态面附近，DNN 预测的极限状态面与真实结果整体吻合较好。这说明所提方法能够将采样逐步引导至各极限状态分支附近的关键区域。

为分析判定阈值$\Delta$的影响，分别取 1、0.5、0.2、0.1 和 0.01，其余参数保持不变。如图 2 所示，随着$\Delta$由 1 减小至 0.1，失效概率相对误差和极限状态函数调用次数总体下降。较大的$\Delta$会使样本剔除频繁触发，可能过早移除部分具有全局响应信息的样本。

当Δ进一步减小至 0.01 时，样本剔除频率降低，远离极限状态面的样本保留相对较多。综合比较，Δ = 0.1时失效概率相对误差和极限状态函数调用次数均达到较低水平，后续算例采用该取值。

图 3 展示了所提方法在主动学习迭代过程中的失效概率演化。随着主动学习的进行，失效概率估计值逐渐接近 MCS 参考值，并在后续迭代中保持稳定。该现象说明所提方法能够通过持续更新实验设计改善对极限状态面的近似，并具有较好的收敛性能。

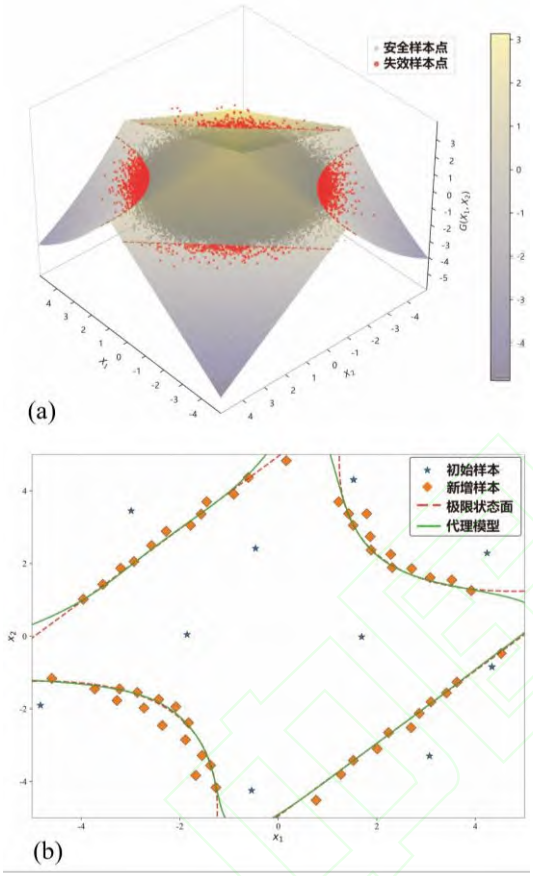
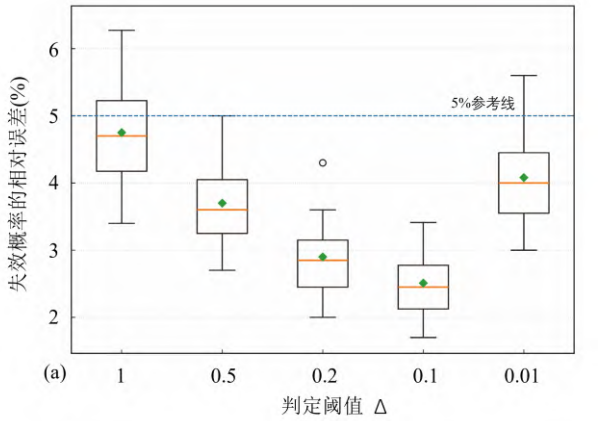



图 1 所提方法在算例 1 中的主动采样结果：（a）真实极限状态面与失效区域；（b）样本分布与预测极限状态面



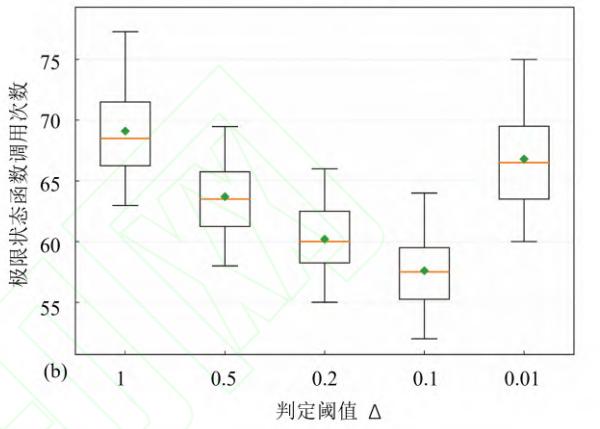




图 2 不同判定阈值Δ下的参数敏感性分析：（a）失效概率相对误差；（b）极限状态函数调用次数

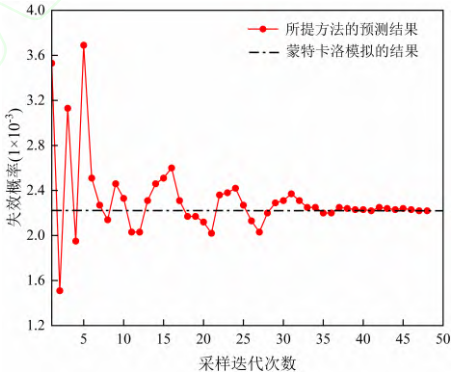



图 3 二维示例的失效概率演化

## 3.2 屋面桁架结构

算例 2 为经典的屋面桁架结构[21]，如图 4 所示。

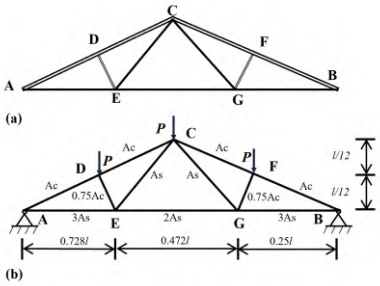



图 4 屋架结构示意图及受力图

下弦和拉杆的材料为钢材，上弦杆和压杆的材料是钢筋混凝土，承受均匀分布载荷 q。将均布荷载转化为集中力$P = ql/4$，施加在 C、D、F 三个节

点上。上述随机变量的概率分布参数见表 2，且相互独立。

表 2　屋面桁架结构的随机变量信息

| 变量 | 物理意义 | 单位 | 参数分布 | 均值 | 标准差 |
|---|---|---|---|---|---|
| $q$ | 均匀载荷 | N/m | 正态分布 | 20000 | 2000 |
| $l$ | 杆长 | m | 正态分布 | 13.5 | 0.5 |
| $A_c$ | 混凝土截面积 | $m^2$ | 正态分布 | 0.04 | 0.008 |
| $A_s$ | 钢材截面积 | $m^2$ | 正态分布 | $9.82\times10^{-4}$ | $6\times10^{-5}$ |
| $E_c$ | 混凝土弹性模量 | N $/m^2$ | 正态分布 | $3\times10^{10}$ | $3\times10^{9}$ |
| $E_s$ | 钢材弹性模量 | N $/m^2$ | 正态分布 | $1.2\times10^{11}$ | $1.2\times10^{10}$ |

以节点 C 的竖向位移作为结构性能指标，其极限状态函数定义为：

$$G(q,l,A_c,E_c,A_s,E_s)=Y_{allow}-Y_c \quad (13)$$

其中，$Y_{allow}$为允许位移阈值，取 0.03m；$Y_c$为节点 C 的位移。$Y_c$的表达式为：

$$Y_c=\frac{ql^2}{2}\left(\frac{3.81}{A_cE_c}+\frac{1.13}{A_sE_s}\right) \quad (14)$$

表 3 汇总了不同方法在该算例下的计算结果。

表 3　不同方法对算例 2 的结果

| 方法 | $N_{call}$ | $P_f$(×10$^{-2}$) | $\varepsilon_{Pf}$(%) | cov$(P_f)$ (%) |
|---|---|---|---|---|
| MCS | $1\times10^6$ | 7.162 | - | 0.36 |
| AK-MCS-U | 156 | 7.19 | 0.42 | 0.36 |
| AK-MCS-EFF | 57.54 | 8.17 | 14.13 | 0.34 |
| ESC+RLCB | 96.46 | 7.43 | 3.74 | 0.35 |
| BSC+RLCB | 72.42 | 7.40 | 3.32 | 0.35 |
| 所提方法 | 64.5 | 7.278 | 1.62 | 0.36 |

由表 3 可知，所提方法得到的失效概率为$7.278\times10^{-2}$，相对误差为 1.62%，平均极限状态函数调用次数为 64.5 次，表明其能够以较低计算成本获得接近 MCS 参考值的失效概率估计。与其他代理模型方法相比[22]，AK-MCS-U 具有更低的相对误差，但其函数调用次数约为所提方法的 2.4 倍；AK-MCS-EFF 的函数调用次数略低，但相对误差达到 14.13%。ESC+RLCB 和 BSC+RLCB 的函数调用次数及相对误差均高于所提方法。结果表明，所提方法能够以较少的极限状态函数调用次数获得接近参考结果的失效概率估计，在该算例中表现出较好的计算精度与效率。

### 3.3　40 维可靠性问题

算例 3 用于评估所提方法在高维可靠性问题中的适用性[23]。该算例包含 40 个对数正态随机变量，其极限状态函数定义为：

$$G(x_1,\ldots,x_n)=\left(n+3\sigma\sqrt{n}\right)-\sum_{i=1}^{n}x_i \quad (15)$$

其中，$x_i$表示服从对数正态分布的随机变量，其均值为 1，标准差$\sigma$为 0.2。本算例取随机变量维数$n=40$。表 4 给出了不同方法在该算例下的计算结果。

表 4　不同方法对算例 3 的结果

| 方法 | $N_{call}$ | $P_f$(×10$^{-3}$) | $\varepsilon_{Pf}$(%) | cov$(P_f)$ (%) |
|---|---|---|---|---|
| MCS | $3\times10^5$ | 1.932 | - | 4.15 |
| AK-MCS-U | 112 | 1.813 | 6.16 | 4.28 |
| AK-MCS-EFF | 124 | 1.813 | 6.16 | 4.28 |
| WS-DNN | 62 | 1.810 | 6.32 | 4.28 |
| ASS-DNN | 60.8 | 1.918 | 0.72 | 4.17 |
| 所提方法 | 87.6 | 1.924 | 0.41 | 4.16 |

由表 4 可知，所提方法得到的失效概率为$1.924\times10^{-3}$，相对误差仅为 0.41%，与 MCS 参考结果较为接近。与 AK-MCS-U 和 AK-MCS-EFF 相比[23]，二者的失效概率估计值均为$1.813\times10^{-3}$，相对误差均为 6.16%，且极限状态函数调用次数分别为 112 次和 124 次。这一差异可能与高维随机变量空间下 Kriging 类代理模型的建模难度增加有关。随着随机变量维数增加，有限训练样本对极限状态面附近关键区域的覆盖更加困难，从而可能影响失效概率估计精度。与 DNN 类方法相比，WS-DNN 的函数调用次数为 62 次，但其失效概率估计值为$1.810\times10^{-3}$,相对误差为 6.32%；ASS-DNN 的失效概率估计值为$1.918\times10^{-3}$，相对误差为 0.72%，且函数调用次数为 60.8 次。相比之下，所提方法虽然需要 87.6 次极限状态函数调用，但相对误差进一步降低至 0.41%，表明其在该 40 维可靠性问题中具有较高的失效概率估计精度。

### 3.4　桁架桥结构

算例 4 为涉及有限元分析的 23 杆桁架桥结构[13]，如图 5 所示。结构由 11 根水平杆件和 12 根斜杆件组成，其截面面积和杨氏模量分别记为$A_1$、$E_1$和$A_2$、$E_2$。桁架顶部节点承受 6 个竖向集中荷载$P_1$–$P_6$。上述荷载和结构参数共构成 10 个相互独立的随机变量，其概率分布参数见表 5。

表 5　10 维桁架结构的随机变量信息

| 变量 | 分布类型 | 均值 | 标准差 |
|---|---|---|---|
| $P_1-P_6$(N) | Gumbel 分布 | $5\times10^4$ | $7.5\times10^3$ |
| $A_1$(m²) | 对数正态分布 | $2\times10^{-3}$ | $2\times10^{-4}$ |
| $A_2$(m²) | 对数正态分布 | $1\times10^{-3}$ | $1\times10^{-4}$ |
| $E_1$(Pa) | 对数正态分布 | $2.1\times10^{11}$ | $2.1\times10^{10}$ |
| $E_2$(Pa) | 对数正态分布 | $2.1\times10^{11}$ | $2.1\times10^{10}$ |

采用 Abaqus 建立 23 杆桁架桥有限元模型。所有杆件均采用 T2D2 二节点线性桁架单元模拟。结

构两端采用简支边界条件。水平杆件和斜杆件的截面面积及杨氏模量根据各组随机样本分别赋值。

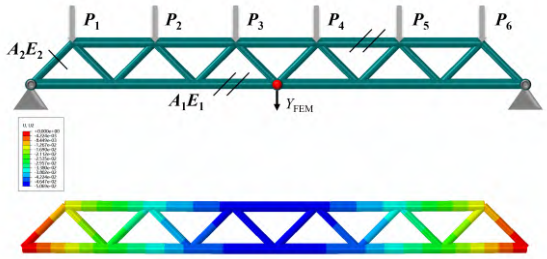



图 5 23 杆桁架结构示意图

以图 5 中红色节点的竖向位移作为结构性能响应。相应的极限状态函数[13]定义为：

$$G(\boldsymbol{X}) = Y_{allow} - Y_{FEM} \tag{16}$$

其中，$Y_{FEM}$为红色节点竖向位移值，由 Abaqus 有限元分析获得允许位移阈值$Y_{allow}$=0.11m。当$G(\boldsymbol{X}) > 0$时结构安全；当$G(\boldsymbol{X}) \le 0$时结构失效。

表 6 不同方法对算例 4 的结果

| 方法 | $N_{call}$ | $P_f$(×10$^{-3}$) | $\varepsilon_{Pf}$(%) | cov($P_f$) (%) |
|---|---|---|---|---|
| MCS | $10^6$ | 8.839 | - | 1.06 |
| AK-MCS-U | 552 | 8.834 | 0.06 | 1.06 |
| AK-SS | 574 | 8.949 | 1.25 | 1.05 |
| RBF-GA(a) | 105 | 8.963 | 1.40 | 1.05 |
| RBF-GA(b) | 148 | 8.146 | 7.84 | 1.10 |
| RBF-EIF | 139.5 | 8.859 | 0.23 | 1.06 |
| RBF+PRF | 99.4 | 8.871 | 0.36 | 1.06 |
| Kriging+PRF | 91.2 | 8.829 | 0.11 | 1.06 |
| 所提方法 | 87.6 | 8.845 | 0.07 | 1.06 |

由表 6 可知，所提方法得到的失效概率为$8.845 \times 10^{-3}$，相对误差仅为 0.07%，平均有限元调用次数为87.6次。与AK-MCS-U和AK-SS相比[13]，所提方法在保持相近估计精度的同时，将有限元调用次数由 552 次和 574 次降至 87.6 次，显著降低了计算成本。与 RBF-GA、RBF-EIF、RBF+PRF 和 Kriging+PRF 等代理模型方法相比，所提方法也以较少的有限元调用次数获得了接近 MCS 参考结果的失效概率估计。该有限元算例表明，所提方法具有较好的工程适用性。

## 4. 结论与未来工作

提出一种基于主动学习深度神经网络的结构可靠性分析方法，通过优化关键样本的选取与更新，提高 DNN 模型对极限状态面的近似能力。四个典型算例验证了所提方法的有效性，主要结论如下：

（1）所提主动采样策略能够根据当前代理模型预测逐步识别潜在极限状态区域，并引导新增样本向极限状态面附近集中，从而提高关键样本的获取效率和极限状态面的表征能力。

（2）样本剔除策略能够根据新增样本的真实极限状态函数值调整实验设计组成，提高极限状态面附近关键样本的占比，从而增强代理模型对关键区域的近似能力。

（3）四个算例结果表明，所提方法能够以较少的极限状态函数调用获得较高精度的失效概率估计。在多失效模式、高维和隐式函数等不同类型的可靠性问题中，所提方法均表现出良好的适用性。

尽管所提方法在多个算例中表现出较好的性能，但目前主要针对静态结构可靠性问题进行了验证，其在小失效概率和动力可靠性问题中的适用性仍需进一步研究。后续将重点研究自适应采样方法，拓展其在复杂结构可靠性分析中的应用。

## 参 考 文 献

[1] 董宏英，巩涛，曹万林，等. 轻钢组合预制混凝土屋盖结构受力性能试验研究[J]. 华中科技大学学报(自然科学版)，2025，53(2)：69-77.

[2] 朱宏平，杨泽亮，艾德米. 混凝土结构内部温度滞后效应对植入式 PZT 导纳的影响研究[J]. 华中科技大学学报(自然科学版)，2026，54(2)：1-8.

[3] WANG T，LI J，LU D，et al. A point mapping strategy-based sparse grid integration method for statistical moments estimation and structural reliability analysis[J]. Computer Methods in Applied Mechanics and Engineering，2024，430：117238.

[4] ECHARD B，GAYTON N，LEMAIRE M. AK-MCS: an active learning reliability method combining Kriging and Monte Carlo simulation[J]. Structural Safety，2011，33(2)：145-154.

[5] TEIXEIRA R，NOGAL M，O’CONNOR A. Adaptive approaches in metamodel-based reliability analysis: a review[J]. Structural Safety，2021，89：102019.

[6] 李宁，张孝航. 基于重点区域采样深度神经网络代理模型的可靠性分析方法[J]. 工程力学，2026，43(5)：24-32.

[7] SUN H，BAO Y. An active learning method based on Monte Carlo dropout neural network for high-dimensional reliability analysis[J]. Reliability Engineering & System Safety，2025，262：111169.

[8] BAI Z，SONG S. Structural reliability analysis based on neural networks with physics-informed training samples[J]. Engineering Applications of Artificial Intelligence，2023，126：107157.

[9] XIANG Z，CHEN J，BAO Y，et al．An active learning method combining deep neural network and weighted sampling for structural reliability analysis[J]．Mechanical Systems and Signal Processing，2020，140：106684．
[10] LIEU QX，NGUYEN KT，DANG KD，et al．An adaptive surrogate model to structural reliability analysis using deep neural network[J]．Expert Systems with Applications，2022，189：116104．
[11] ZHANG K，ZHAI D，LUO H，et al．UDDS-DNN: uncertainty and distance-driven sequential sampling deep neural network method for structural reliability analysis[J]. Machines，2026，14(2)：233．
[12] ZHAI D，YANG Z，LUO H，et al．AL-IDNN: active learning method based on incremental updating of deep neural networks for structural reliability analysis[J]．Reliability Engineering & System Safety，2026，276：112879．
[13] HONG L，LI H，FU J．A novel surrogate-model based active learning method for structural reliability analysis[J]．Computer Methods in Applied Mechanics and Engineering，2022，394：114835．
[14] 吕利叶，鲁玉军，王硕，等．代理模型技术及其应用：现状与展望[J]．机械工程学报，2024，60(3)：254-281．
[15] LI G，MA S，ZHANG D，et al．An efficient sequential anisotropic RBF reliability analysis method with fast cross-validation and parallelizability[J]．Reliability Engineering & System Safety，2024，241：109600．
[16] LV Z，LU Z，WANG P．A new learning function for Kriging and its applications to solve reliability problems in engineering[J]．Computers & Mathematics with Applications，2015，70(5)：1182-1197．
[17] SUN Z，WANG J，LI R，et al．LIF: a new Kriging based learning function and its application to structural reliability analysis[J]．Reliability Engineering & System Safety，2017，157：152-165．
[18] 范文亮，余书君，李正良．基于新学习函数与收敛准则的改进 AK-MCS 方法[J]．华中科技大学学报(自然科学版)，2024，52(1)：99-105．
[19] CAO L，GONG SG，TAO YR，et al．A RBFNN based active learning surrogate model for evaluating low failure probability in reliability analysis[J]．Probabilistic Engineering Mechanics，2023，74：103496．
[20] ROY A，CHAKRABORTY S．Support vector regression based metamodel by sequential adaptive sampling for reliability analysis of structures[J]．Reliability Engineering & System Safety，2020，200：106948．
[21] 易家祥．改进的序贯 Kriging-蒙特卡洛可靠性分析方法及在船舶结构设计中的应用[D]. 武汉：华中科技大学，2021．
[22] YI J，ZHOU Q，CHENG Y，et al．Efficient adaptive Kriging-based reliability analysis combining new learning function and error-based stopping criterion[J]．Structural and Multidisciplinary Optimization，2020，62(5)：2517-2536．
[23] BAO Y，XIANG Z，LI H．Adaptive subset searching-based deep neural network method for structural reliability analysis[J]．Reliability Engineering & System Safety，2021，213：107778．